

Reporte ejecutivo

Resumen ejecutivo

Este proyecto desarrolla un análisis 360° sobre manifestaciones de violencia y agresión en datos colombianos. Primero se analiza el reporte oficial de delitos sexuales de la Policía Nacional mediante PySpark, luego se construyen modelos de Machine Learning con Spark ML a partir de perfiles municipio-año, y finalmente se aplica NLP a un corpus colombiano de tweets etiquetados como ciberacoso. Los resultados muestran concentración territorial de reportes, patrones útiles para clasificar municipios-año con alta proporción de delitos relacionados con menores de 14 años y buen desempeño de un modelo TF-IDF para detectar ciberacoso en texto colombiano.

Metodología

En el Bloque 1 se realizó un análisis exploratorio con PySpark sobre el dataset de delitos sexuales de la Policía Nacional. Se cargaron 392.576 registros, se revisó el esquema, se limpiaron variables de fecha y se construyeron variables como año, mes y trimestre. Para evitar comparar años incompletos, el análisis principal se concentró en el periodo 2010-2025, con 386.224 registros. Se aplicaron transformaciones con filter, groupBy, withColumn y join, además de conteos por departamento, género, grupo etario, tipo de delito y armas/medios reportados. También se revisaron nulos, duplicados y posibles atípicos.

En el Bloque 2 se transformó el dataset original en una base agregada por municipio-año. Esta decisión fue necesaria porque en la base original CANTIDAD vale 1 en cada fila, por lo que cada registro individual contiene poca información para modelado. Se construyeron 8.813 perfiles municipio-año con al menos 5 reportes, incluyendo proporciones por género, edad, medios reportados y variables de rezago. La variable objetivo fue identificar municipios-año con proporción de reportes relacionados con menores de 14 años igual o superior al percentil 75, cuyo umbral fue 0,72. Se aplicó un pipeline con StringIndexer, OneHotEncoder, VectorAssembler y StandardScaler, seguido de PCA, K-Means, Regresión Logística, Random Forest y validación cruzada.

En el Bloque 3 se trabajó con un corpus colombiano de tweets etiquetados como ciberacoso o no ciberacoso. Se cargaron 2.565 documentos válidos, se aplicó tokenización con RegexTokenizer, remoción de stop words en español, cálculo de tokens, vocabulario, TTR y hapax legomena. Después se usó CountVectorizer e IDF para construir vectores TF-IDF y entrenar una Regresión Logística. Finalmente, se comparó este modelo con un modelo RoBERTuito disponible en pysentimiento para hate speech en español.

Resultados clave

En el Bloque 1, el análisis exploratorio mostró una concentración territorial clara. Entre 2010 y 2025 se registraron 386.224 reportes. Bogotá acumuló 70.515 reportes, equivalentes al 18,26% del total; Antioquia registró 47.705, el 12,35%; y Valle 36.566, el 9,47%. Estos tres departamentos concentraron una parte importante de los registros. Además, los delitos más

frecuentes fueron ARTÍCULO 209. ACTOS SEXUALES CON MENOR DE 14 AÑOS, con 133.818 reportes, y ARTÍCULO 208. ACCESO CARNAL ABUSIVO CON MENOR DE 14 AÑOS, con 82.141 reportes. Este resultado se interpreta desde el tipo penal reportado, no como una medición directa de la edad de la víctima en todos los registros.

En el Bloque 2, la clasificación supervisada permitió identificar perfiles municipio-año con alta proporción de reportes relacionados con menores de 14 años. La clase positiva representó el 25,12% de los casos, por lo que se balanceó únicamente el conjunto de entrenamiento y se mantuvo el conjunto de prueba sin modificar. Random Forest obtuvo accuracy de 0,6769, precision de 0,4170, recall de 0,6821, F1 de 0,5176 y AUC de 0,7511. Con validación cruzada, el mejor Random Forest usó 80 árboles y profundidad máxima 8, con AUC de 0,7524. El balanceo redujo la accuracy, pero mejoró la capacidad de detectar casos altos.

En el Bloque 3, el modelo TF-IDF con Regresión Logística tuvo un desempeño alto en la clasificación de ciberacoso. El corpus tuvo 2.565 tweets válidos, 20.055 tokens limpios, vocabulario de 8.075 términos, TTR de 0,4026 y 5.233 hapax legomena, equivalentes al 64,80% del vocabulario. En clasificación, TF-IDF obtuvo accuracy de 0,9046, F1 de 0,9044 y AUC de 0,9510. En comparación, el modelo pre-entrenado RoBERTa obtuvo accuracy de 0,6161 y F1 de 0,4000 sobre el mismo conjunto de prueba.

Reflexión integradora

Los tres bloques se conectan alrededor del análisis de violencia registrada y agresión en contextos colombianos, aunque desde fuentes distintas. Los Bloques 1 y 2 trabajan con reportes oficiales de delitos sexuales, lo que permite estudiar patrones territoriales, temporales y demográficos mediante PySpark y Spark ML. El Bloque 3 complementa esa mirada con datos textuales de ciberacoso, una forma de agresión que ocurre en espacios digitales y que requiere técnicas de NLP. En conjunto, el proyecto muestra que los datos estructurados permiten describir y modelar patrones agregados, mientras que los datos textuales permiten analizar expresiones lingüísticas asociadas a daño, insulto o agresión.

También se observa una diferencia importante entre los enfoques. En los datos oficiales, el análisis depende de registros administrativos y variables estructuradas como departamento, año, grupo etario y tipo de delito. En NLP, el desempeño depende del vocabulario, del contexto y de las etiquetas del corpus. Por eso el modelo TF-IDF entrenado directamente en tweets colombianos superó al modelo pre-entrenado de Hugging Face, que fue diseñado para hate speech general en español y no específicamente para ciberacoso colombiano. Esta comparación muestra la importancia de usar modelos ajustados al dominio y al contexto del problema.

Limitaciones

La primera limitación es que los datos de delitos sexuales corresponden a reportes registrados, no a la ocurrencia real total del fenómeno. Pueden existir subregistro, cambios

metodológicos, diferencias territoriales en denuncia y procesos de actualización de la fuente. Por esa razón, los resultados no deben interpretarse como tasas reales de victimización.

La segunda limitación es que no se contó con población municipal por año. Esto impidió calcular tasas por 100.000 habitantes y obligó a trabajar con conteos y proporciones internas. Por tanto, los municipios o departamentos con mayor número de reportes no necesariamente tienen mayor riesgo relativo.

La tercera limitación es que existe una posible ambigüedad entre el tipo penal del delito y la variable grupo etario. Por ejemplo, algunos tipos penales hacen referencia explícita a menores de 14 años, pero la variable GRUPO ETARIO presenta una distribución donde predominan los adultos. Por eso no se debe asumir automáticamente que todas las variables describen la misma dimensión del caso sin revisar la documentación completa de la fuente.

La cuarta limitación es que el modelo pre-entrenado usado en NLP no fue entrenado específicamente para ciberacoso colombiano. RoBERTuito sirve como comparación externa, pero su tarea de hate speech no coincide exactamente con la etiqueta ciberacoso, lo que explica parte de su menor desempeño frente al modelo TF-IDF entrenado sobre el corpus local.

Recomendaciones

Para replicar o continuar este análisis, se recomienda primero documentar con claridad la fecha de descarga de las fuentes y conservar copias locales de los datasets usados. Esto es importante porque las bases oficiales pueden actualizarse y producir resultados diferentes en el futuro.

También sería recomendable complementar el dataset de delitos sexuales con población municipal por año, de manera que se puedan calcular tasas y no solo conteos absolutos. Esto permitiría comparar territorios de distinto tamaño de forma más justa.

Para la parte de Machine Learning, conviene mantener la unidad municipio-año, porque permite construir variables más informativas que la fila individual. También sería útil probar modelos adicionales solo si se conserva la interpretabilidad, ya que en este proyecto es importante poder explicar las decisiones durante una sustentación.

Finalmente, para NLP se recomienda usar modelos pre-entrenados como punto de partida, pero validarlos o ajustarlos con corpus colombianos etiquetados. En este proyecto, TF-IDF con Regresión Logística fue más simple, más interpretable y tuvo mejor desempeño que el modelo pre-entrenado, por lo que sería la opción recomendada para una primera versión académica o exploratoria.